MAP07 - Modélisation des feux de forêts

Projet Scientifique Collectif

David HEURTEL–DEPEIGES, Saad SOUILMI, Pierric SPERY,
Germain VIVIER-ARDISSON, Paul ZEINATY

Sommaire

1. Objectifs du PSC
2. Apprentissage de la vitesse
   - Données simulées
   - Approche satellite
3. Apprentissage de l'incertitude
   - Approche quantile
   - Approche distribution
4. Bilan et perspectives

Motivations

- Analyser les risques liés aux feux de forêts en amont et pendant les interventions
- Lien avec l'UIISC5 : améliorer l'outil leur permettant de prévoir les feux
- Faire des mathématiques *appliquées* au concret

Figure – L'UIISC5 en intervention sur un feu en Corse

Contexte / État de l'art

Figure – Mesures de vitesse de propagation en laboratoire, Université de Lorraine

- Différents types de modélisation :
  - Modèles empiriques ;
  - Modèles semi-empiriques ;
  - Modèles physiques.
- Travaux de l'Université de Corse

Objectifs

- Obtenir un émulateur d'un modèle physique basé sur l'apprentissage, plus rapide que ce modèle
- Étudier l'incertitude dans la prédiction de la vitesse du feu
- Étudier un modèle empirique, basé sur des données réelles

Répartition du travail

- Etude préliminaire
- Création de l'émulateur
- Etude de l'incertitude
- Etude d'un modèle empirique

Figure – Définition des principales tâches

Sommaire

1. Objectifs du PSC
2. Apprentissage de la vitesse
   - Données simulées
   - Approche satellite
3. Apprentissage de l'incertitude
   - Approche quantile
   - Approche distribution
4. Bilan et perspectives

Démarche scientifique

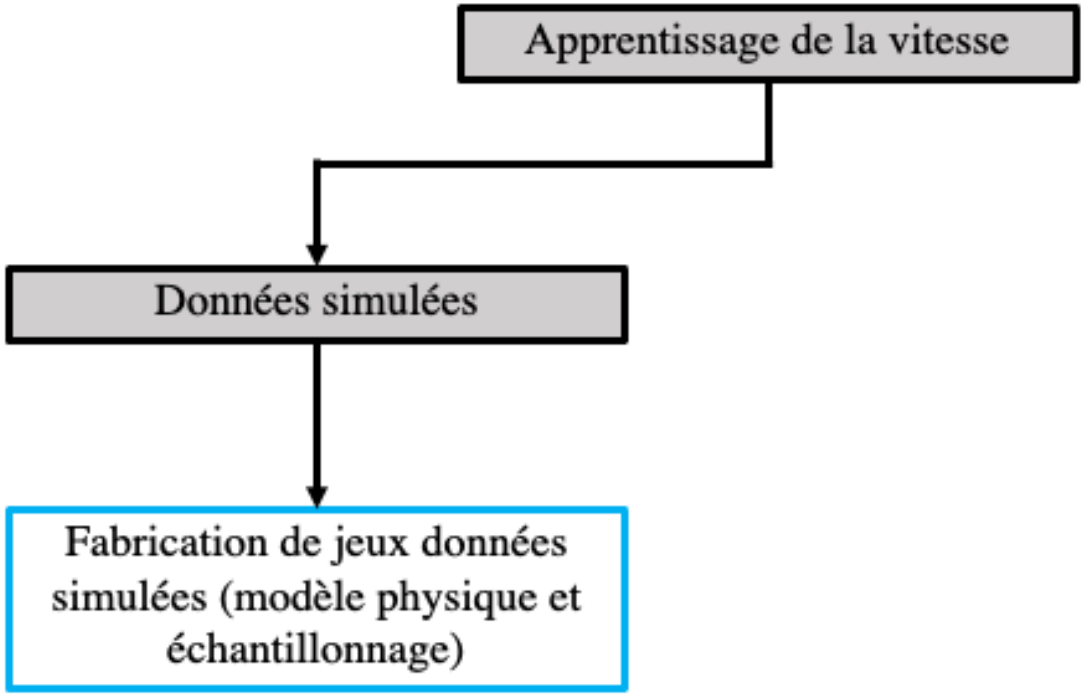

Étude thermodynamique

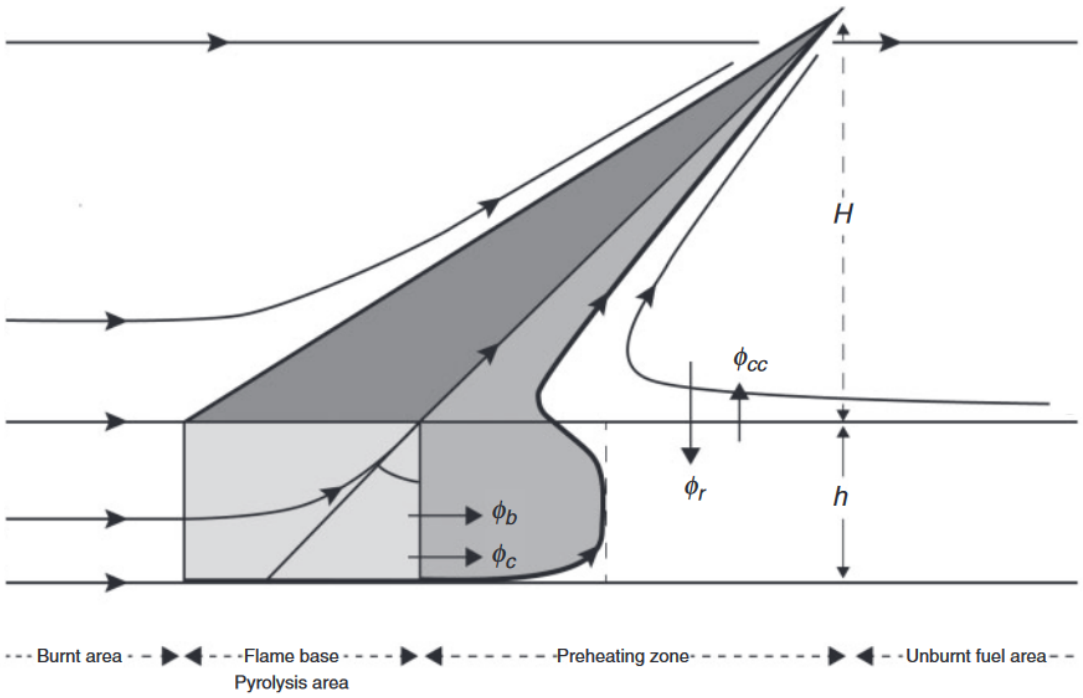

Fig. 1. A qualitative representation of the flaming zone combustion profile and streamlines.

Figure – Les différents flux de chaleur

Génération des jeux de données simulées

Résolution de l'équation *ROS* (non-linéaire algébrique)

Deux méthodes envisagées :

- méthode du point fixe
- méthode de Newton

Ecart en précision : nul
Ecart en temps de calcul : variable et non-significatif

Méthode retenue : point fixe (aussi utilisée par M. Filippi dans ses travaux)

Construction d'une distribution de points

- L'objectif est de générer un nuage de points qui soit "bien distribué" en haute dimension, avec le moins d'échantillons possible.
- On a opté pour les suites à discrépance faible de Hammersley.

Les suites de Halton et de Hammersley

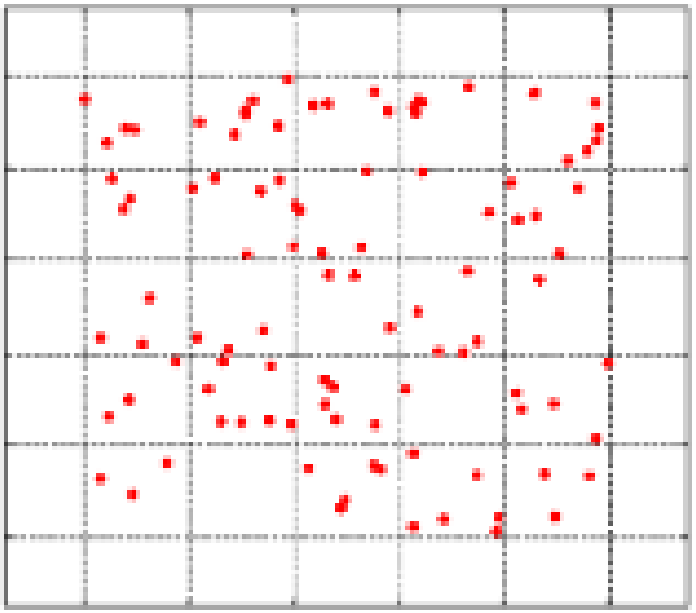

(a) Pseudo-random Points

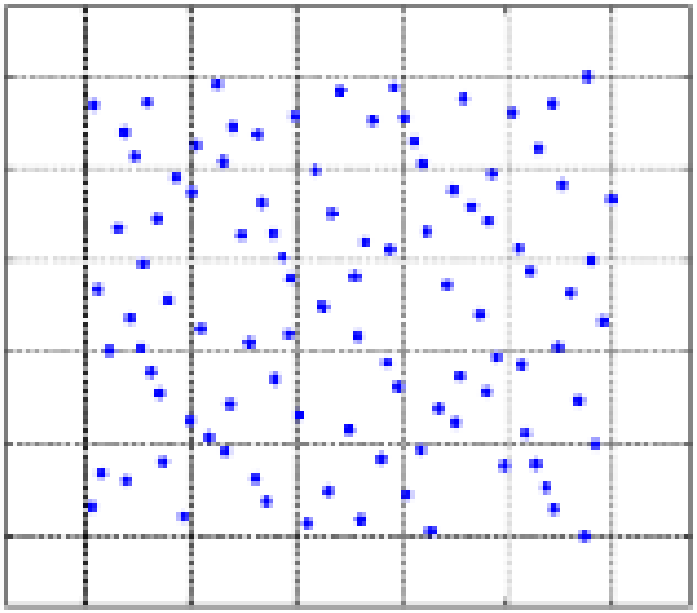

(b) Low-discrepancy Points

Figure – Échantillonage d'un pavé en dimension 2 par des points pseudo-aléatoires ou à discrépance faible

Simulation de Hammersley

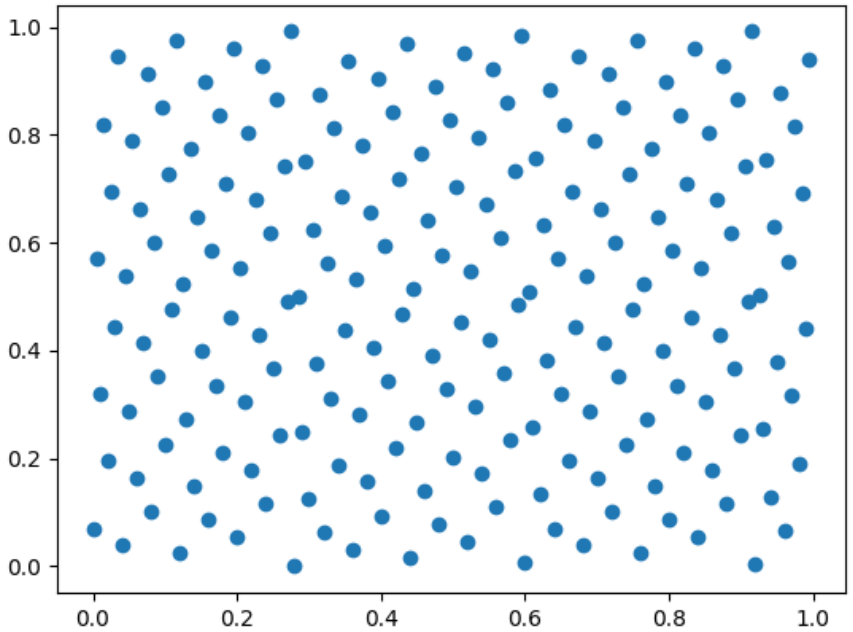

Figure – Simulation de la suite de Hammersley en dimension 2 avec 200 échantillons entre x_{200} et x_{400}.

Démarche scientifique

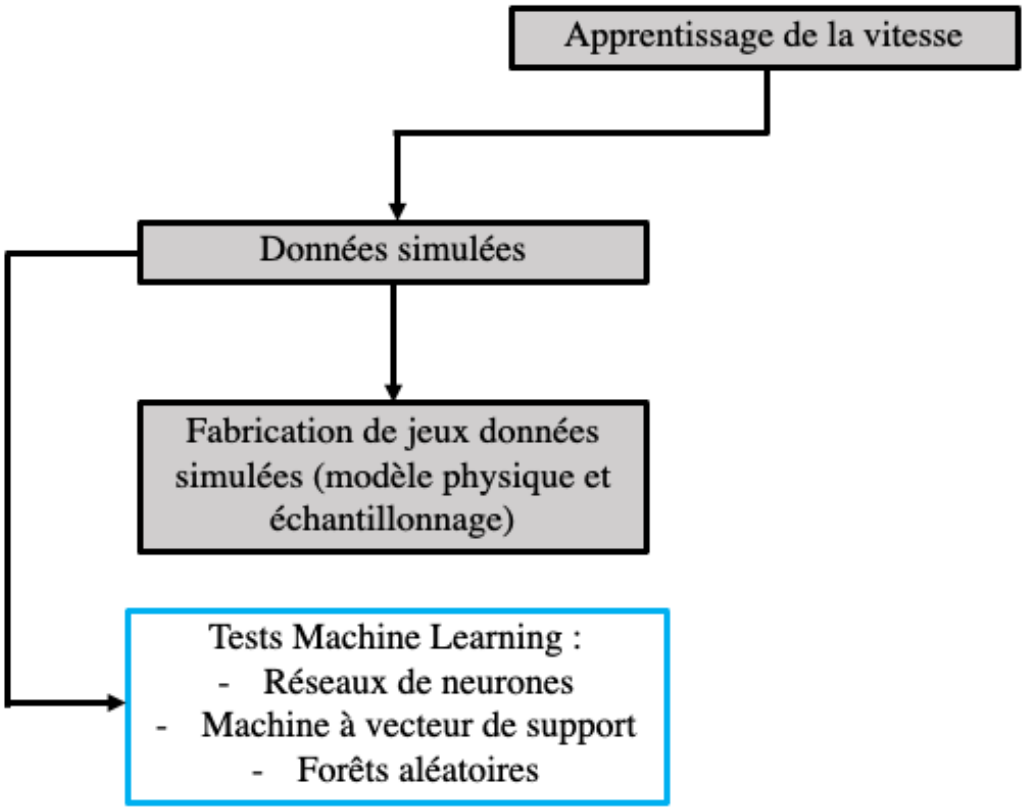

Modèles de Machine Learning : Réseau de Neurones

Régression par Réseau de Neurones : apprentissage de relations complexes et non-linéaires entre les variables.

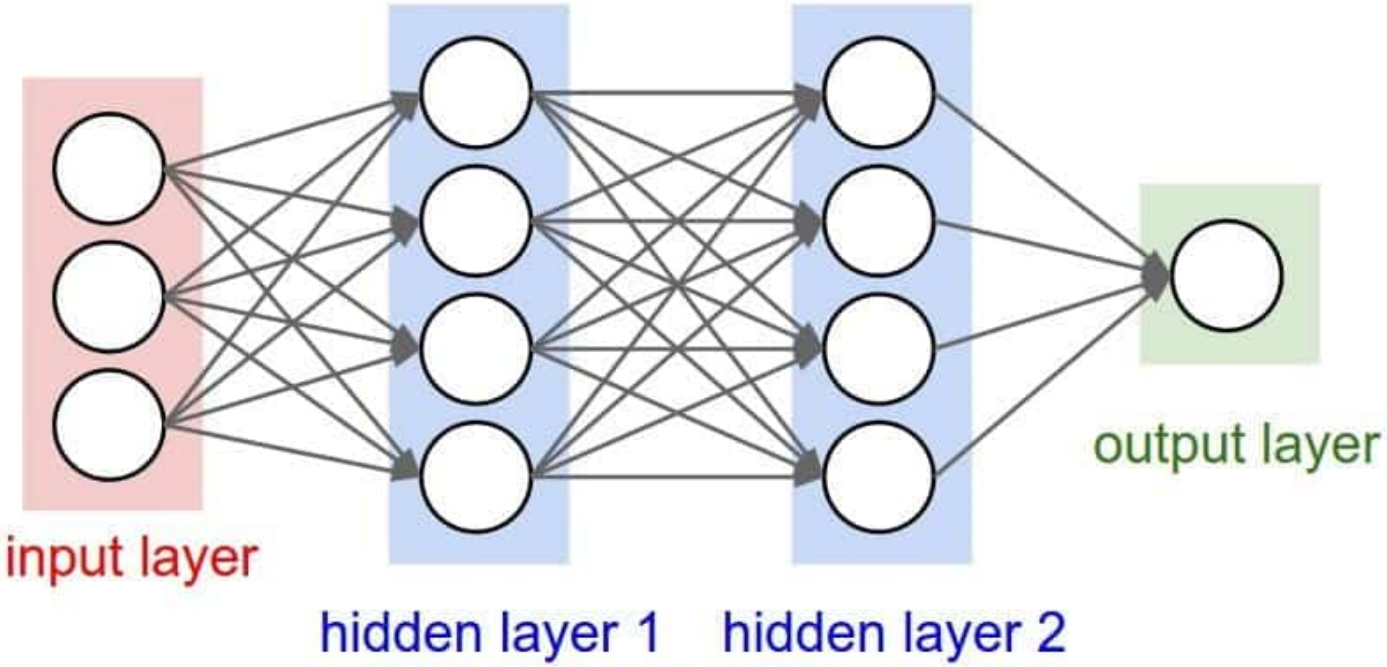

Figure – Architecture d'un réseau de neurones

Modèles de Machine Learning : Réseau de Neurones

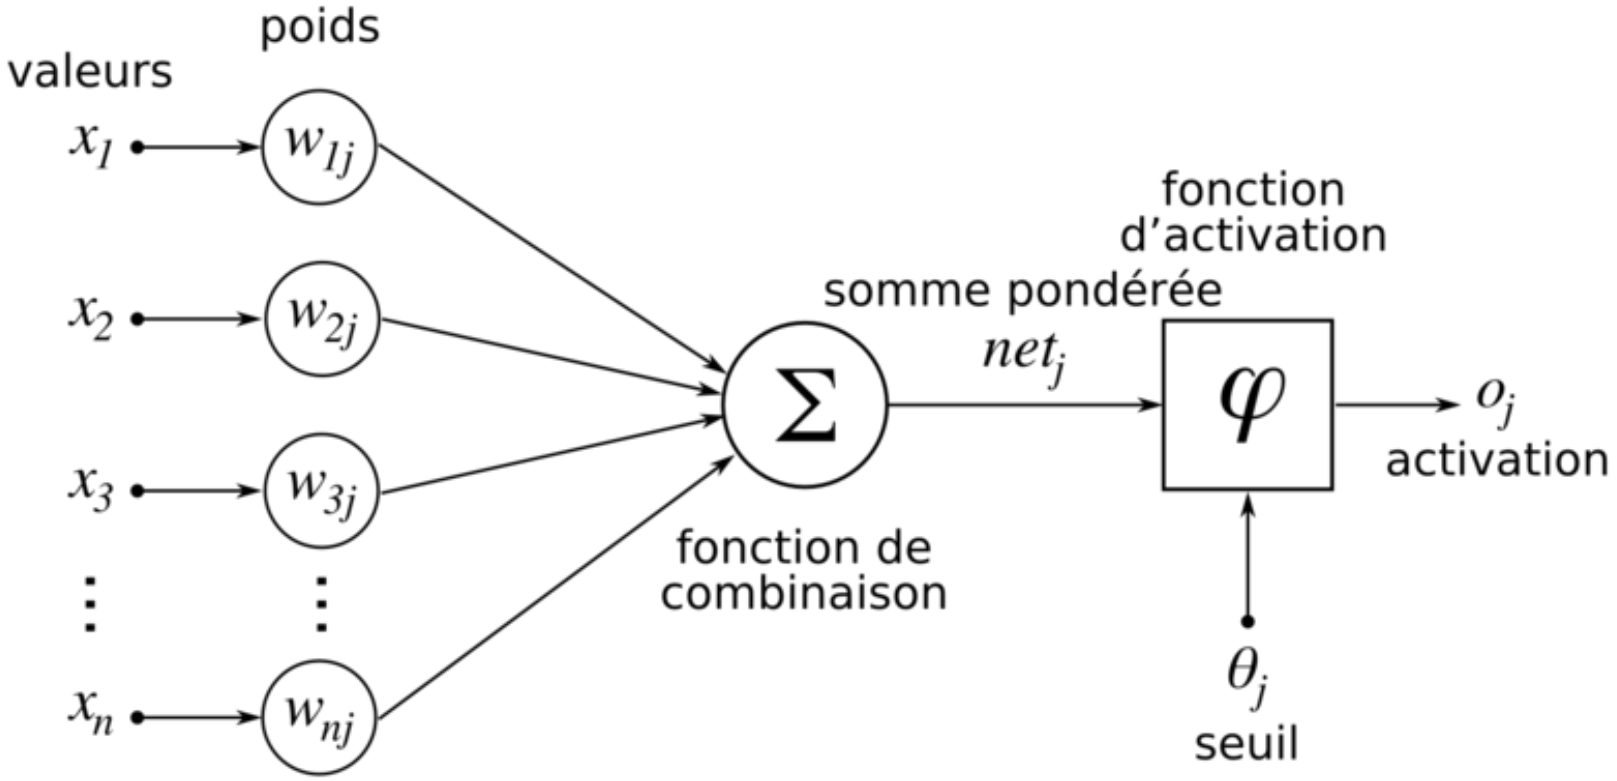

Figure – Fonctionnement et activation des neurones

Modèles de Machine Learning : Réseau de Neurones

Hyperparamètres à régler pour un réseau de neurones :

- Nombre de couches cachées ;
- Nombre de neurones par couche cachées ;
- Type de fonction d'activation (sigmoïde, tangente hyperbolique, ...) ;
- Solveur utilisé pour l'optimisation des poids (« sgd » pour Stochastic Gradient Descent, adam ou lbfgs) et caractéristiques du solver (max-iter, *learning rate*)

Démarche scientifique

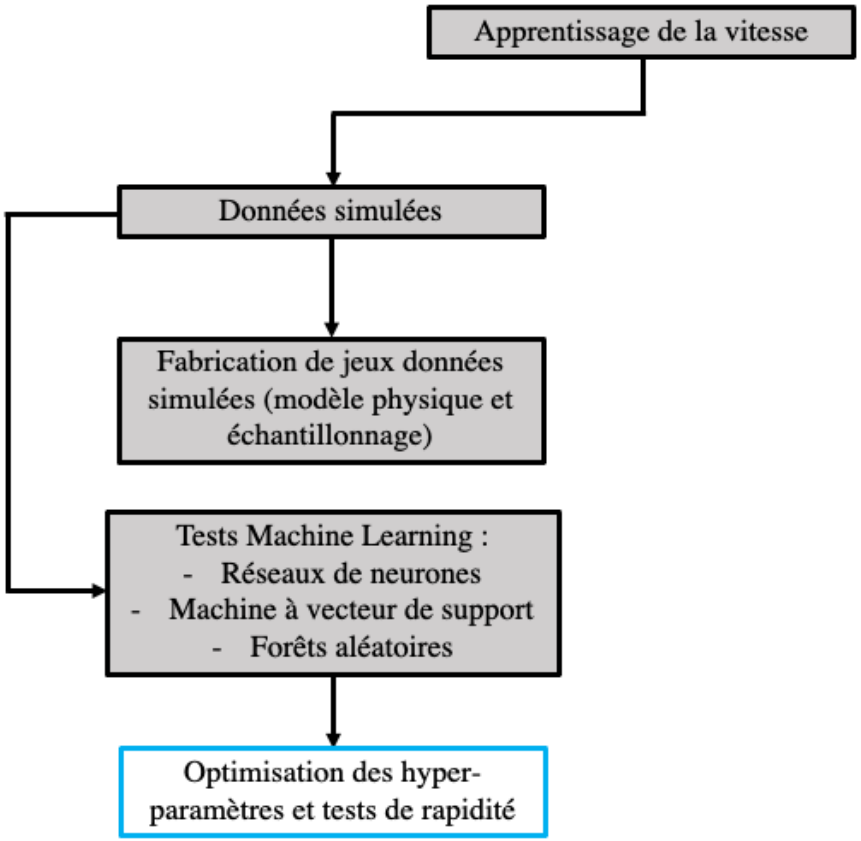

Optimisation des hyperparamètres

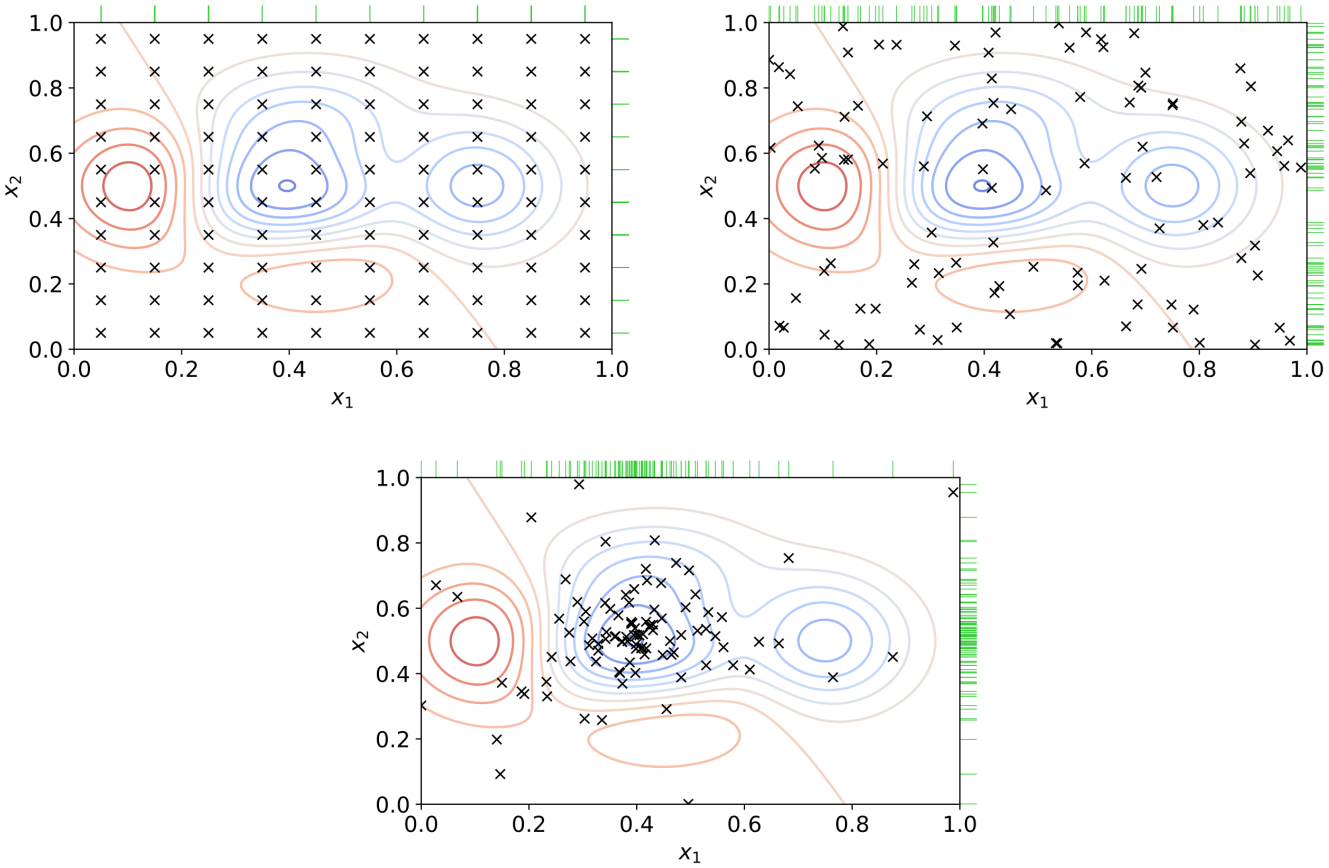

Figure – (a) GridSearch (b) RandomSearch (c) Méthode Bayésienne

Validation croisée

Comment valider nos hyperparamètres ?

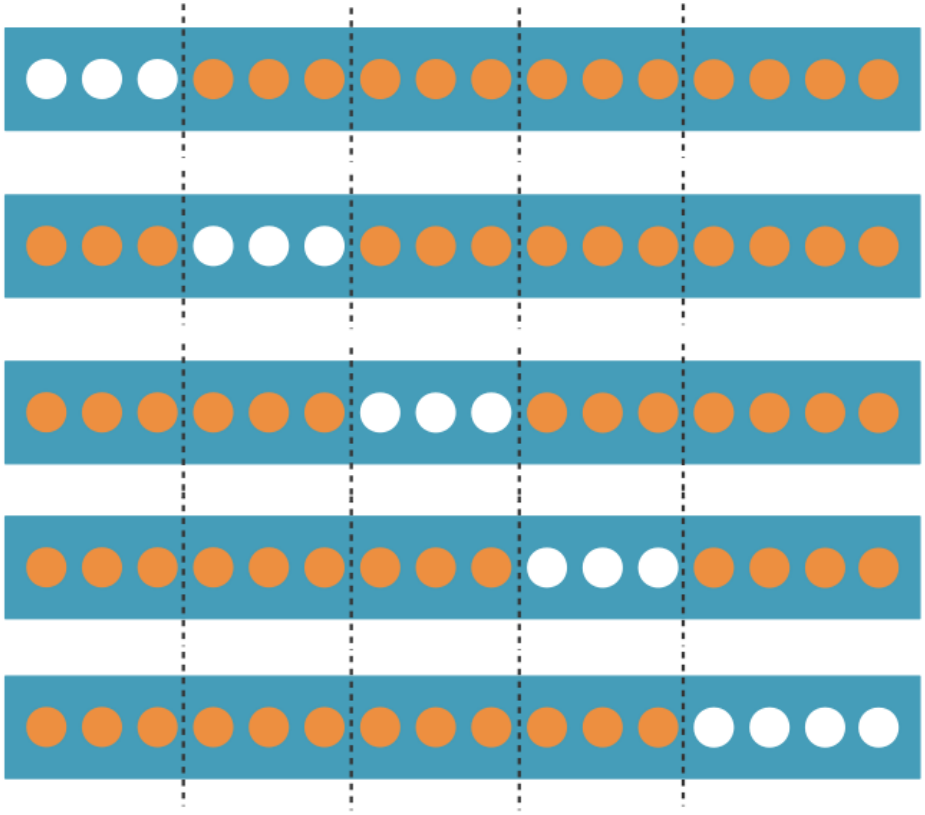

Figure – Principe de la Validation croisée

Optimisation des hyperparamètres : Réseau de Neurones/GridSearch

Nous avons implémenté GridSearch avec validation croisée pour les paramètres cités ci-dessus. Cela nous a permis :

- Optimisation de l'émulateur ;
- Un choix en avance des modèles à utiliser avec les données réelles ;
- Une vérification de généralités "connues" en ML.

Optimisation des hyperparamètres : Généralités connues

- Problèmes autour de la fonction d'activation et du solver utilisé
- Plus important : rôle de la géométrie du réseau, généralisation, apprentissage, par rapport à un émulateur

Résultats

Méthode utilisée	**Score**	**Remarques**
Réseau de neurones (1 couche, 100 neurones)	0.98 ou 0.97	Convergence optimale avec ReLU
Forêts aléatoires	0.75	Sans optimisation : 0.70 - 0.73
SVM	0.70 - 0.80	Problème de temps de calcul quand le paramètre de régularisation est très petit (= score élevé)

Tests de rapidité

- Temps d'exécution minimal. (2×1000 itérations, `Jeu_donnees_out_128.csv`)

  ```
  test_Physique: 0.0010552999999999813s
  test_ResNeur: 0.000408499999991818 2s
  ```

Cela s'explique par l'optimisation de l'algèbre linéaire par rapport au calcul algébrique non-linéaire.

Démarche scientifique

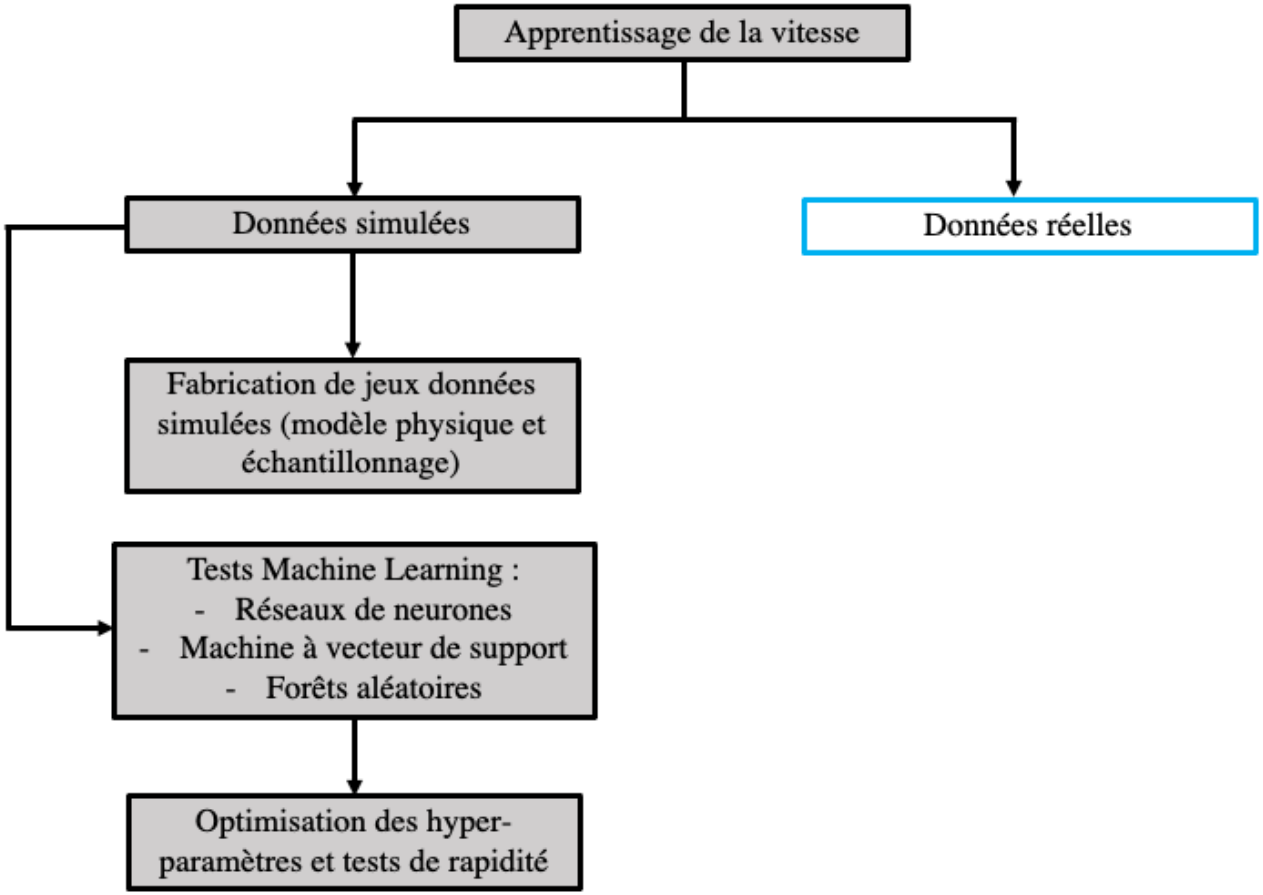

Objectifs

- Adopter une approche purement empirique (plus un émulateur) nécessite des données réelles ;
- Elles permettraient de prendre en compte des phénomènes physiques difficilement modélisables.

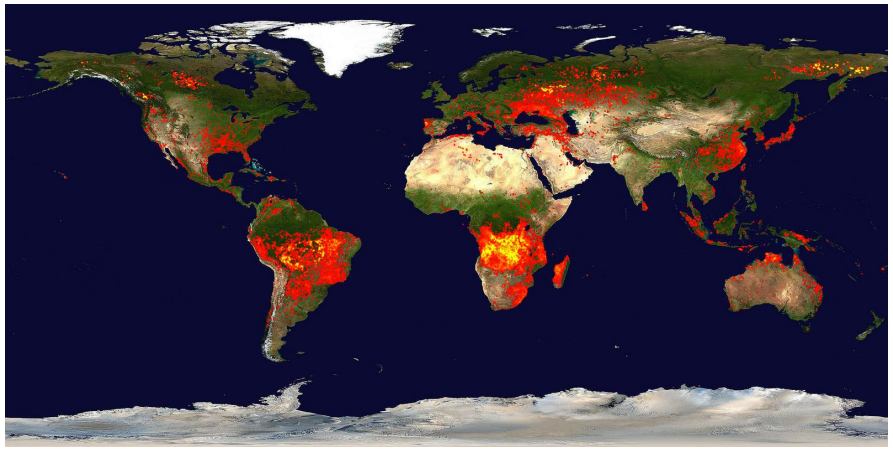

Traitement des données satellites

Exemples de points d'un fichier de données satellites

latitude	longitude	brightness	acq-date	acq-time
29.980009	-81.383148	299.2	2021-07-01	630
30.940664	-88.01963	297.17	2021-07-01	630
31.145298	-87.990707	301.2	2021-07-01	630
31.152466	-87.990257	316	2021-07-01	630

Objectif : Regrouper les points géographiquement proches correspondant à un même feu

$\longrightarrow$ Algorithme de clustering

Traitement des données satellites

Algorithme DBSCAN (Density-Based Spatial Clustering of Applications with Noise)

- Nombre de feux inconnus
- Prendre en compte le bruit
- Possibilité de varier le paramètre de densité pour sélectionner les feux

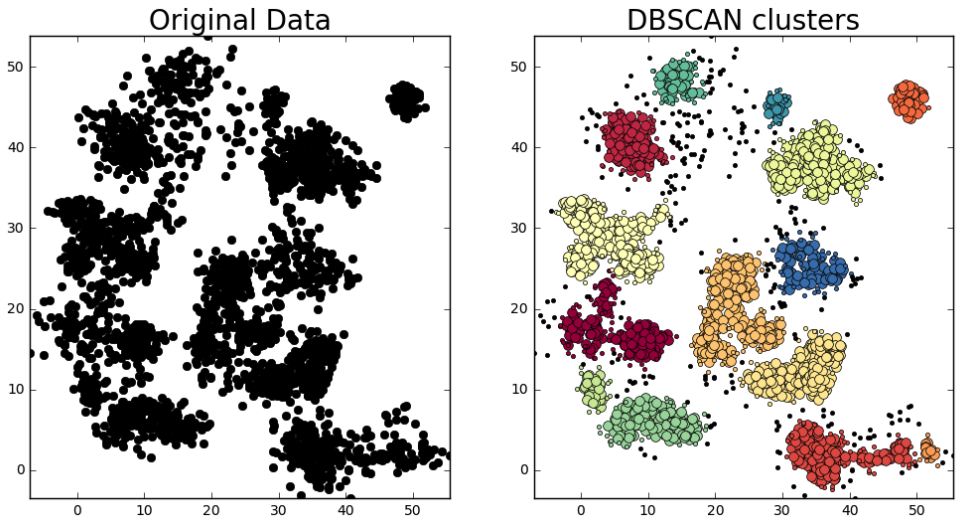

Traitement des données satellites

- Choix des paramètres ϵ et *MinPts*
- Visualisation des résultats

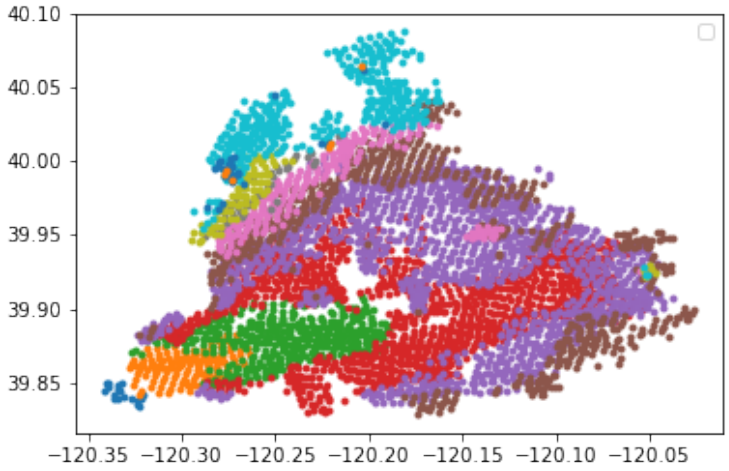

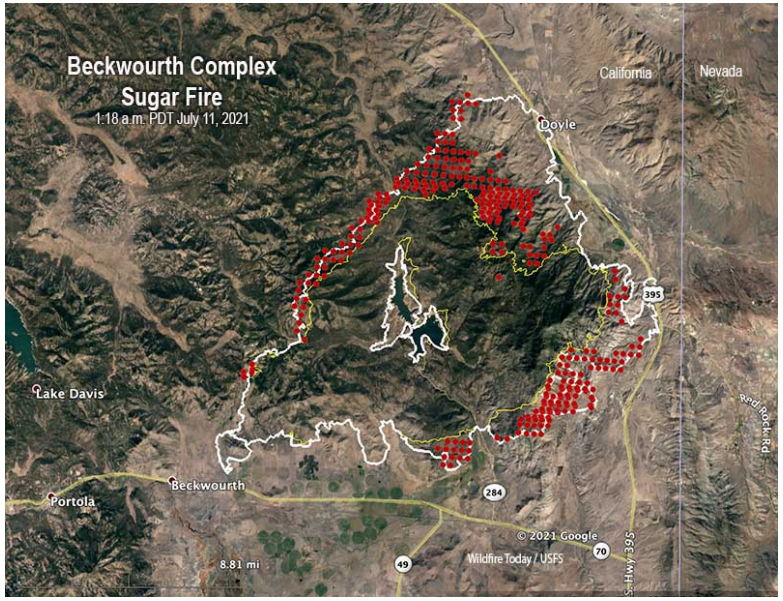

Traitement des données satellites

- Discrétisation et lissage
- Visualisation des résultats

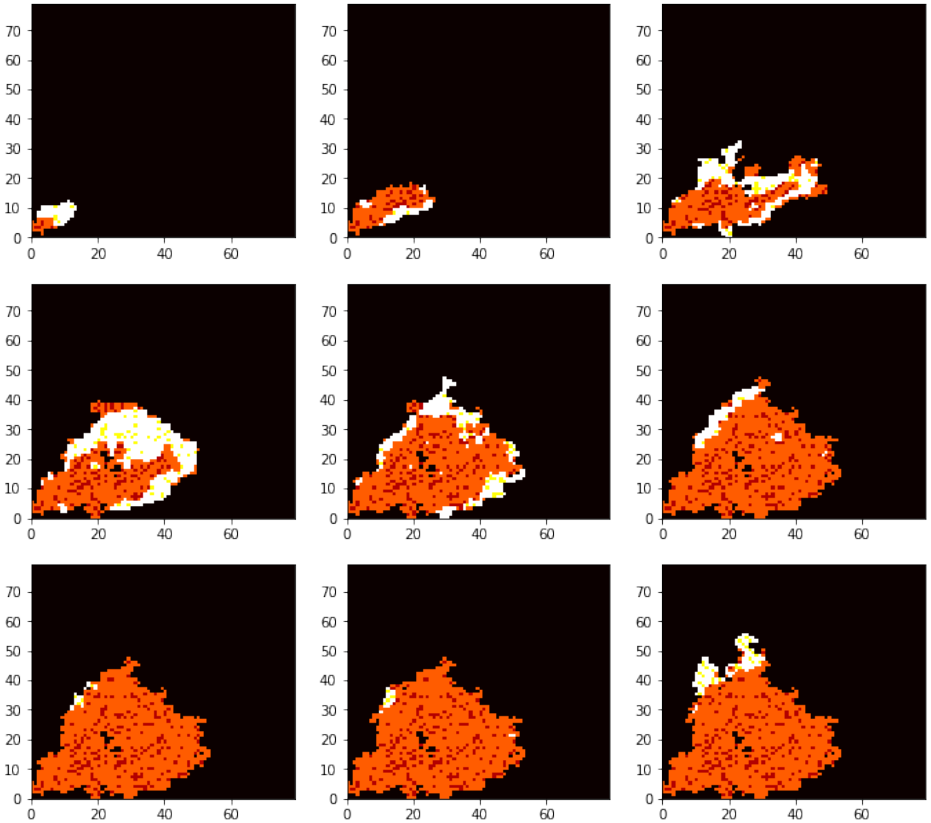

Données géographiques et climatiques

- Meteostat est une API[1] open source qui offre accès à une archive de données météorologiques ;
- On utilise cette API pour automatiser le processus d'acquisition de données ;
- On utilise un algorithme K-NN pour trouver les k stations les plus proches d'un point donné.

1. Une API (*Application Programming Interface*) est une interface logicielle qui permet de « connecter » un logiciel à un autre logiciel afin d'échanger des données et des fonctionnalités.

Démarche scientifique

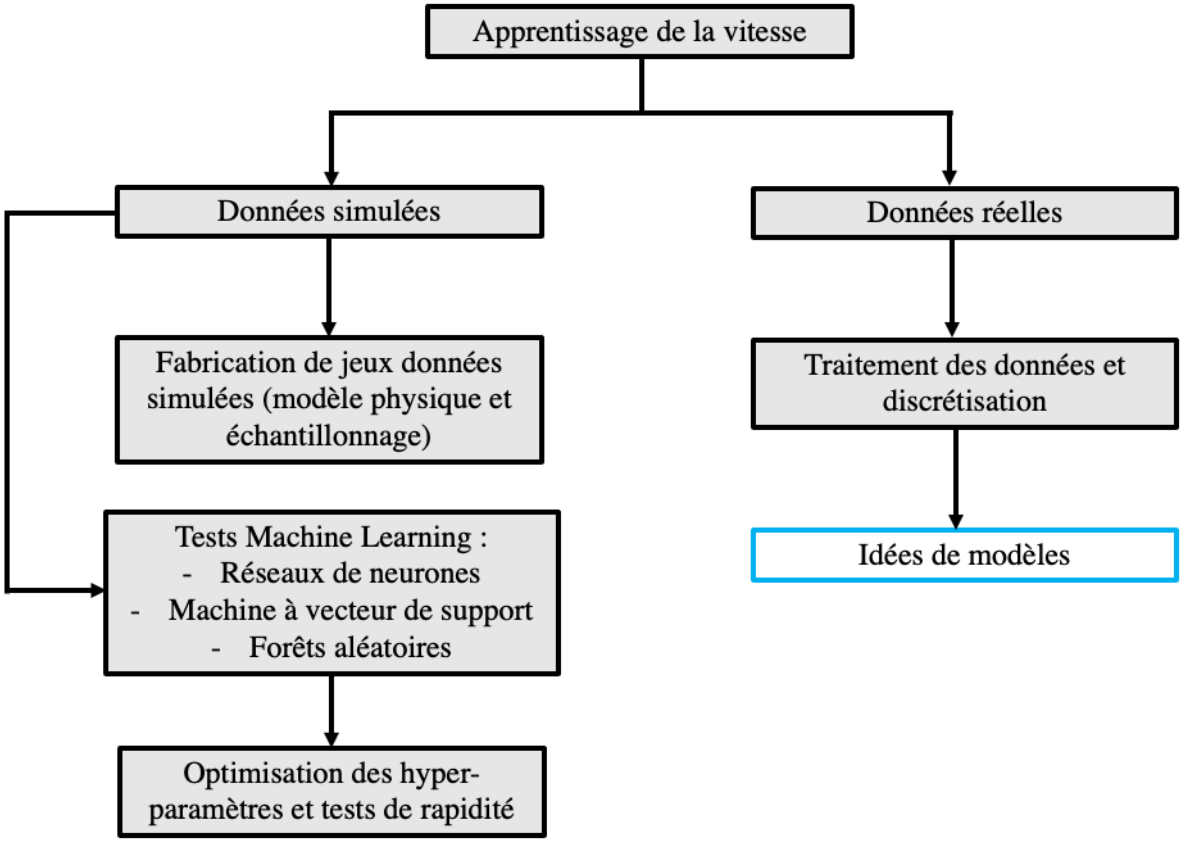

Multiplication des données, idées de modèles

- Réseaux de neurones convolutifs
- La propagation du feu dépend beaucoup des paramètres locaux
- ...et un peu des paramètres généraux (géographie générale de la région, taille du feu)
- Des réseaux de neurones convolutifs permettraient de prendre en compte ces phénomènes.

Multiplication des données, idées de modèles

Problèmes :

- Besoin de beaucoup de données
- Des photographies satellites à intervalles temporels variables

Idées de solution :

- Multiplication des données (à partir d'un feu en faire plusieurs exemples d'entraînement)

Sommaire

1. Objectifs du PSC
2. Apprentissage de la vitesse
   - Données simulées
   - Approche satellite
3. Apprentissage de l'incertitude
   - Approche quantile
   - Approche distribution
4. Bilan et perspectives

Démarche scientifique

Objectif : Déterminer une incertitude sur la vitesse de propagation

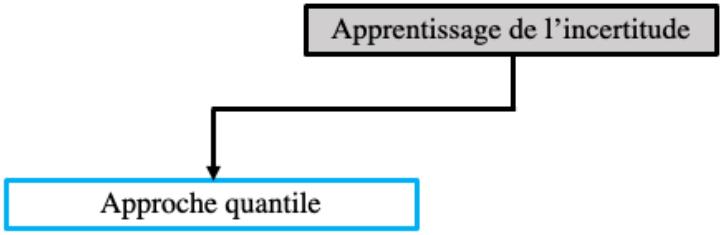

- Un processus chaotiques (mécanique des fluides) sur la mesure des paramètres physiques...
- donner un intervalle de confiance pour la *RoS* en un point.

Démarche scientifique

Objectif : Déterminer une incertitude sur la vitesse de propagation

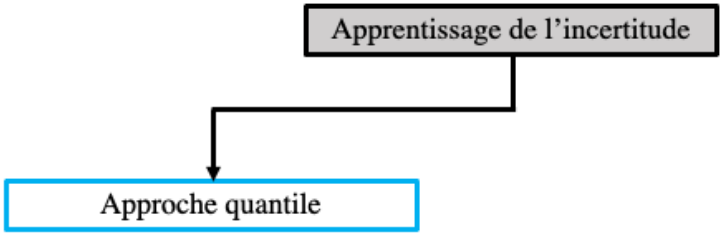

- jeu de données bruité...incertitude dans les mesures physiques des paramètres

Résultats préliminaires

- Régression quantile linéaire
- Problème de stockage de données sur pour une régression aussi simple
- Plus petits jeux de données : convergence de l'algorithme.
- Nous pensions que la performance n'était pas très bonne mais nous calculions mal la probabilité (approchée) que la *RoS* réelle soit inférieure au quantile considéré.

Résultats

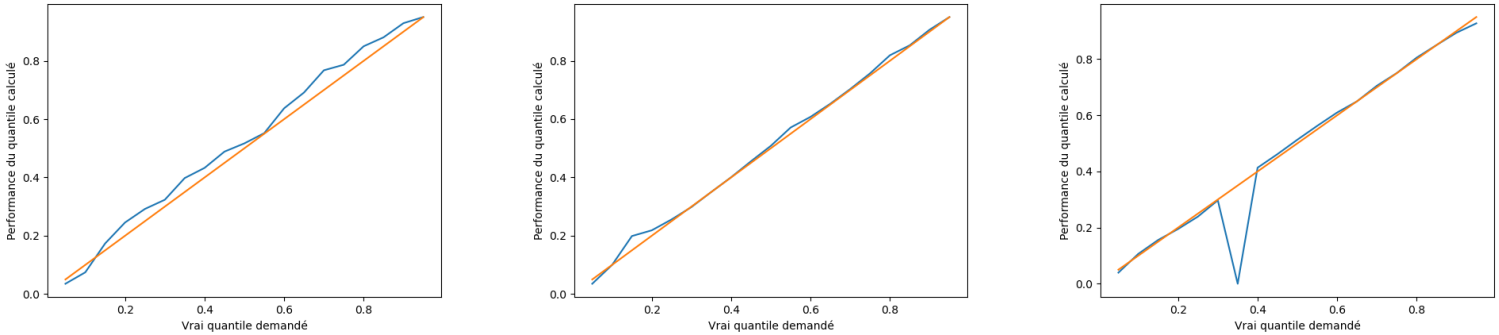

Figure – Performance de la regression quantile sur un jeu de donnée à (a) 128 points (b) 256 points (c) 512 points

- Une bonne performance apparente, même avec de petits jeux de données
- en réalité, des problèmes sous-jacent, similaires à ceux évoqués dans notre rapport intermédiaire.

Résultats régression quantile

- Une tendance malgré tout à sous-estimer les risques
- Des quantiles pour lesquels il n'y a pas convergence

Démarche scientifique

Objectif : Déterminer une incertitude sur la vitesse de propagation

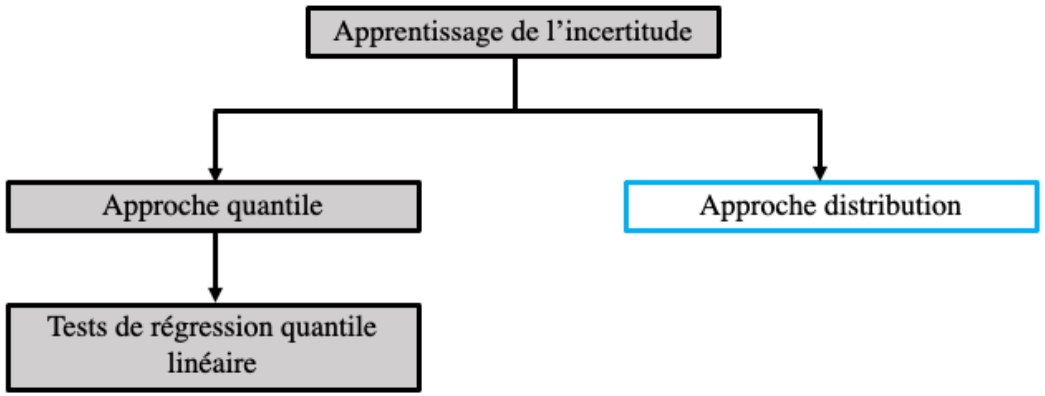

$\longrightarrow$ Approche distribution $\longrightarrow$ Un problème de classification ?

Sommaire

1. Objectifs du PSC
2. Apprentissage de la vitesse
   - Données simulées
   - Approche satellite
3. Apprentissage de l'incertitude
   - Approche quantile
   - Approche distribution
4. Bilan et perspectives

Démarche scientifique

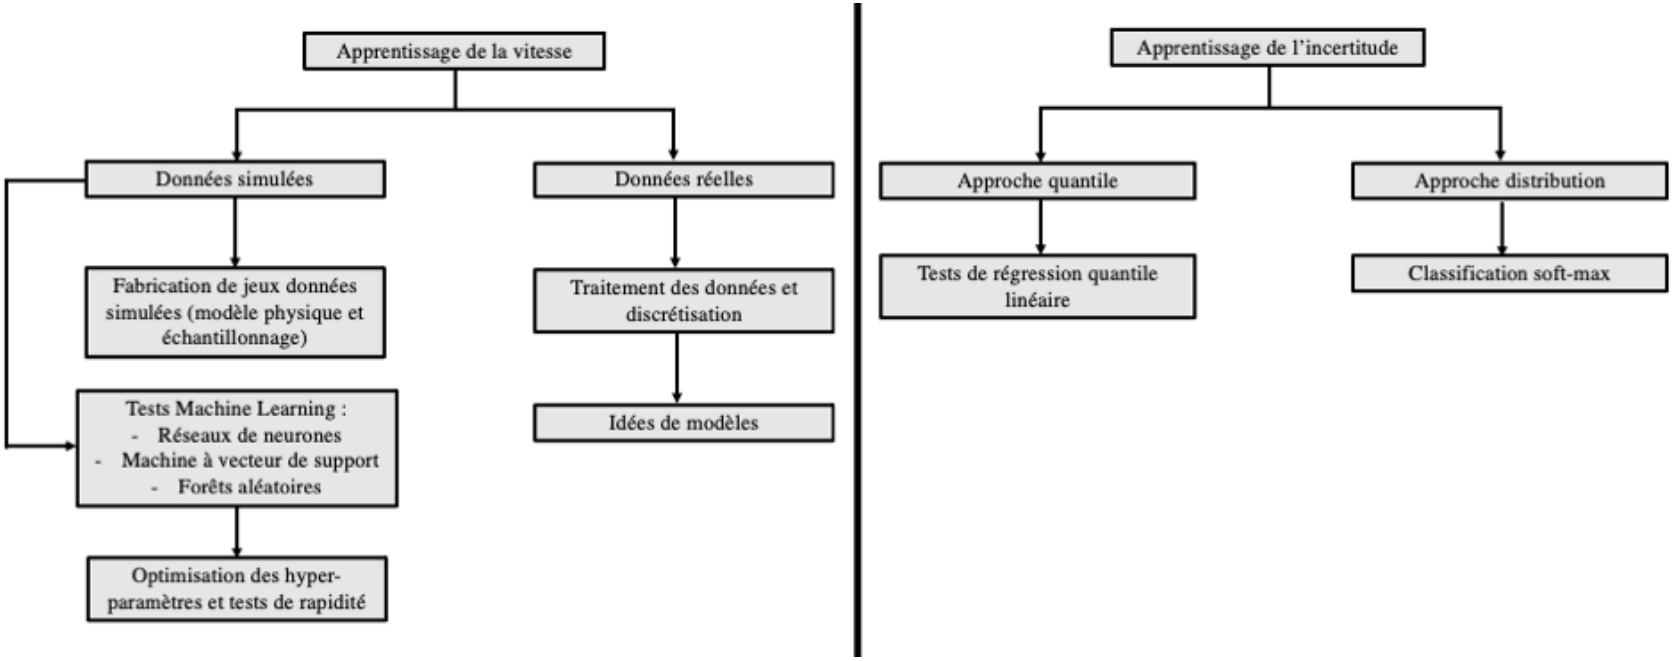

$\longrightarrow$ Cycle de la donnée : captation, traitement et analyse

Bilan scientifique

- ☑ Émulateur du modèle Balbi20 plus rapide que le modèle physique
- ☑ Étude poussée des hyperparamètres pour le réseau de neurones (expérience en *Machine Learning*)
- ☑ Premiers pas dans l'exploitation de données réelles
- ☑ Analyse des limites d'un apprentissage de l'incertitude

Apports du projet commun

- ☑ Concevoir, structurer et mener un projet en équipe
- ☑ Définir et répartir les tâches de façon à travailler efficacement
- ☑ Adapter la démarche scientifique et réviser les objectifs

- ☑ Développer un type d'émulateur très utile dans l'ingénierie
- ☑ Rechercher et exploiter des données scientifiques publiques

Perspectives

- Intégration de l'émulateur au projet ForeFire de l'Université de Corse
- Utilisation de l'émulateur en conditions réelles
- Développer l'approche basée sur les données satellites (peut-être un nouveau sujet de PSC ?)

Annexes

Modèles de Machine Learning : SVM

Régression par Machine à Vecteur de Support

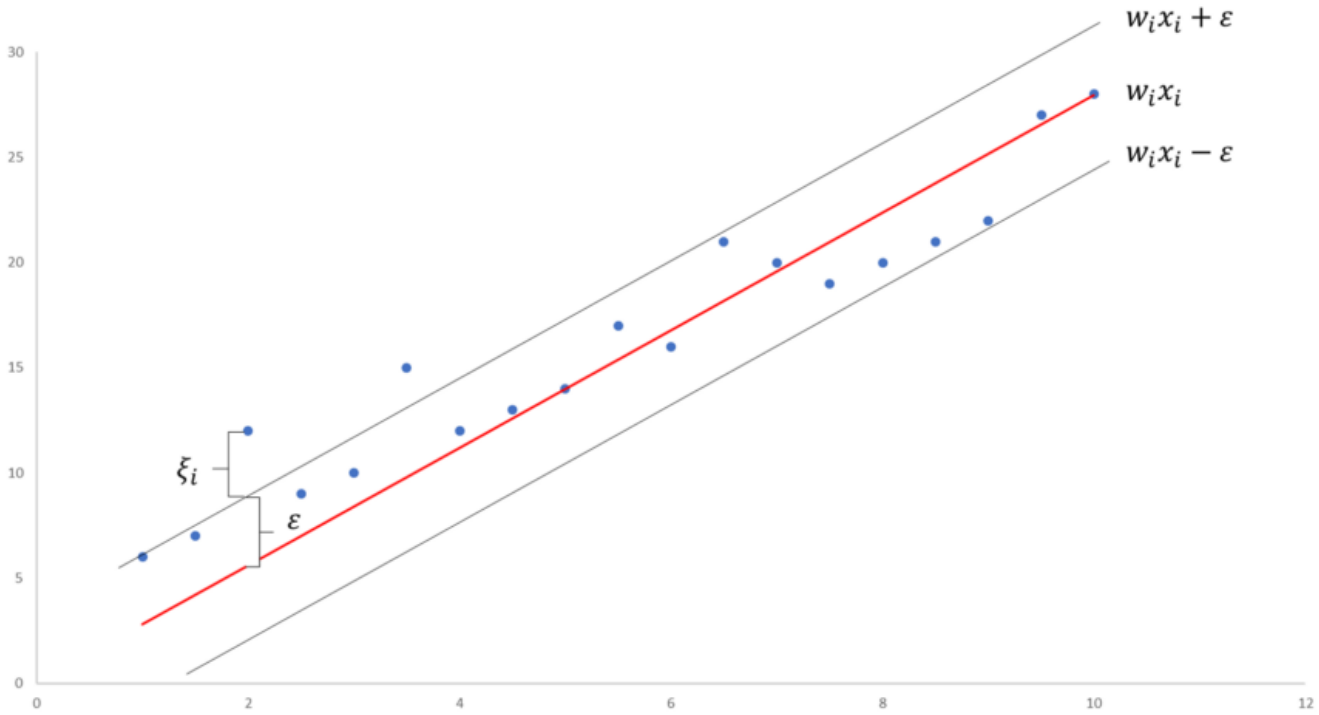

- Fonction objectif : $\min \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{n}(\|\xi_i\|)$
- Contraintes : $\|y_i - w_i x_i\| \leq \epsilon + \|\xi_i\|$

Modèles de Machine Learning : SVM

Comment décrire un phénomène non linéaire avec une SVM ?

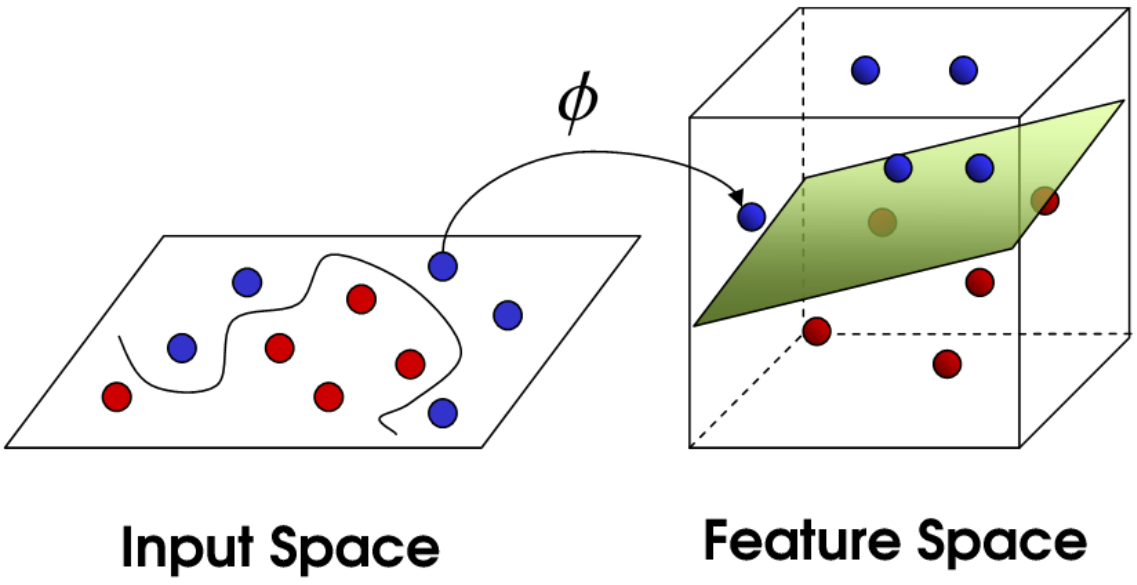

Figure – Astuce du 'Kernel'

Modèles de Machine Learning : SVM

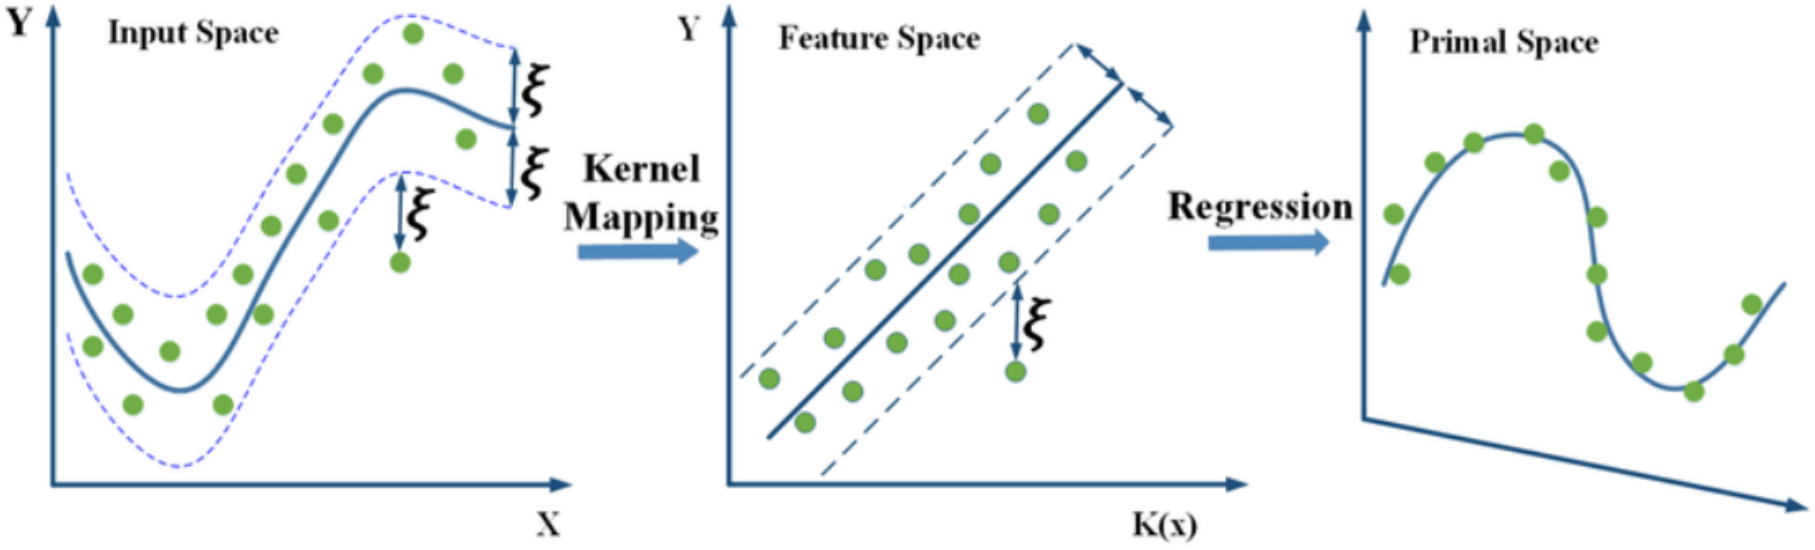

Figure – Application à la SVR

Modèles de Machine Learning : SVM

Hyperparamètres à régler pour une régression par SVM :

- C : Poids entre la régularisation l_2 et la fonction d'attache aux données ;
- ϵ : Taille de la marge ;
- ϕ : Fonction kernel (linéaire, polynômial, 'rbf', sigmoïde...).

Optimisation des hyperparamètres : SVM/GridSearch (début) et méthodes bayésiennes

Nous avons implémenté effectuée manuellement une *GridSearch* au début de l'exploration. Mais les résultats étaient vraiment inférieurs donc nous avons ensuite utilisé des outils déjà codés (bibliothèque skopt) pour effectuer une optimisation par méthode bayésienne :

- Même si théoriquement équivalents, les SVM étaient inférieures aux réseaux de neurones

Modèles de Machine Learning : Random Forest

Régression par Forêt aléatoire

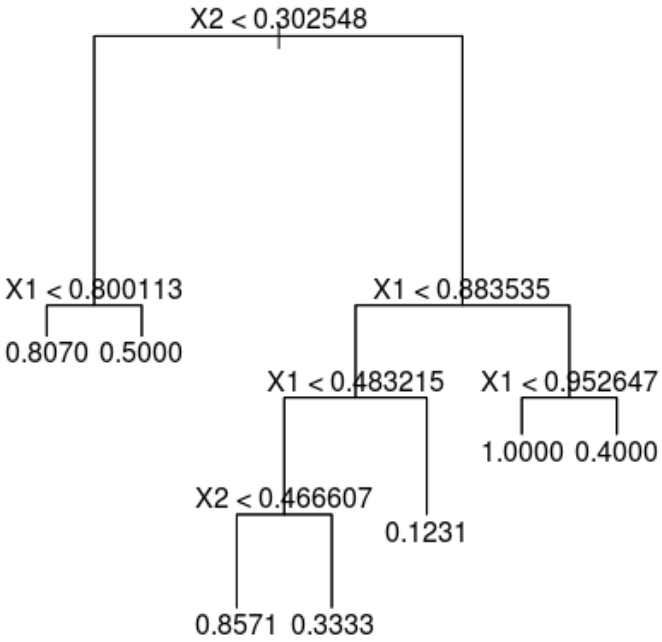

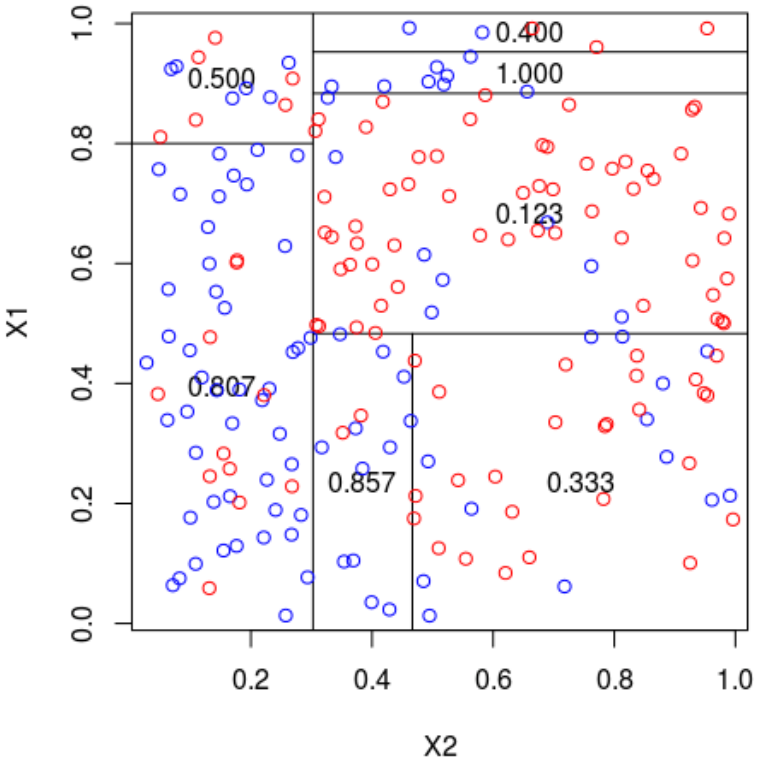

Figure – Arbre de décision

Modèles de Machine Learning : Random Forest

On moyenne l'output de plusieurs arbres de décision, qui forment notre forêt.

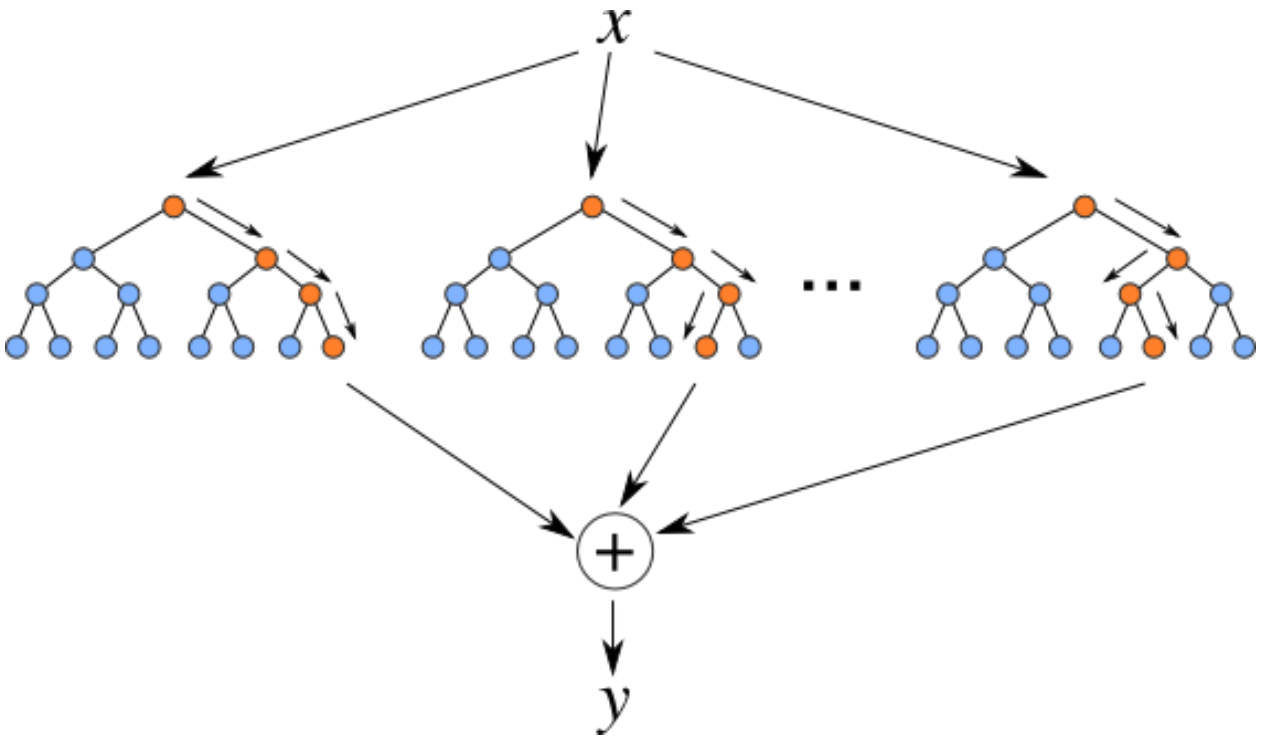

Figure – Forêt aléatoire

Modèles de Machine Learning : Random Forest

Principaux hyperparamètres à régler pour une régression par Forêt aléatoire :

- Nombre d'arbres dans la forêt ;
- Fonction mesurant la qualité d'un noeud (impureté de Gini, entropie au sens de Shannon...) ;
- Profondeur maximale des arbres ;
- Nombre minimal d'échantillons pour séparer un noeud ;
- Nombre minimal d'échantillons pour constituer une feuille ;

Optimisation des hyperparamètres : RandomSearch/RandomForest

Nous n'avons pas exploré par une *RandomSearch* l'ensemble des des paramètres ci-dessus : tous sauf la fonction mesurant la qualité d'un noeud puisque pas proposé par la bibliothèque en question. Celle-ci utilise l'impureté de Gini.

- Une première forêt aléatoire (avec les hyperparamètres par défaut) satisfaisante mais inférieure en score aux réseaux de neurones, équivalent aux SVM décrite lors de GridSearch
- Peu d'arbres, performance encore moindre
- Globalement, pas une grande amélioration.